电 子 科 技 大 学

2022级本科毕业设计（论文）开题报告表

学号：2022060901026	姓名： 黄鹏羽	学院：自动化工程学院	专业：测控技术与仪器
论文题目	基于迁移学习的多工况逆变系统故障检测		
题目来源：1.交流学生学分认定 ☑2.科研 3.生产 4.教学（含实验） 5.创新创业			
成果形式：1.硬件 2.硬件+软件 3.软件 ☑4.理论研究			

学位论文研究内容

1．研究现状及发展态势

1.1 逆变系统故障检测的研究背景与意义

逆变器作为电力电子变换系统的核心能量转换单元，广泛应用于新能源发电、轨道交通及工业自动化驱动等关键领域［1］。由于其内部功率半导体器件（如绝缘栅双极型晶体管（Insulated Gate Bipolar Transistor, IGBT）、金属氧化物半导体场效应晶体管（Metal-Oxide-Semiconductor Field-Effect Transistor, MOSFET））长期处于高频开关、高电压、高结温及复杂动态负载的恶劣运行环境下，极易因热应力、电应力疲劳发生开路或短路故障。相关行业可靠性调研报告显示，电力电子变换器中约有 31% 的非计划停机故障归因于功率半导体器件的失效［2］。

在实际工业现场，逆变器往往是系统链条中的关键节点。一旦功率器件发生微小早期故障而未被及时准确检测，其异常波形及环流可能迅速诱发直流侧电容过压、电机绕组过流等次生损害，最终导致系统性崩溃，造成高昂的停机修复成本甚至严重的人员伤亡事故［3］。因此，针对复杂运行工况研究具备高鲁棒性和高泛化能力的逆变器故障诊断算法，不仅是保障电力电子装备安全运行的技术核心，更是推动新能源系统向智能化、免维护方向发展的迫切需求［4］。

1.2 传统故障检测方法及其局限性

早期的逆变器故障检测技术研究主要聚焦于机理建模与特征工程，按照实现路径可分为基于解析模型的方法与基于信号处理的方法：

(1)基于解析模型的方法：

该类方法通过逆变器的电路拓扑构建精确的数学描述，利用实测信号与模型估计值之间的残差进行故障判定。例如，Isermann［5］提出了一种

基于线性状态观测器的故障诊断框架，其核心思想是建立逆变器开关逻辑与输出电流的等效状态方程，通过实时监测观测残差来定位功率器件的开路故障位置。此外，Gao 等［6］进一步探索了参数估计法的应用，利用最小二乘法等手段在线识别逆变器的电感、电阻等关键参数，通过监控参数的异常跳变来反演器件的健康状态。Du 等［7］则针对三相桥臂结构提出了模型参考预测电流法，通过构造代价函数来评估实测电流与理想状态的偏差。然而，此类方法极度依赖精准的物理参数，在实际多工况运行中，负载的非线性波动、控制策略的动态调整以及由于温升导致的器件参数偏移，极易引发“模型失配”现象。一旦物理模型无法实时覆盖全运行域，工况切换产生的虚假残差将导致误报率显著上升，难以满足复杂动态场景下的可靠性要求［8，4］。

(2)基于信号处理的方法：

此类方法的核心在于通过数学变换从原始电流或电压信号中提取具有判别性的“故障指纹”。Maidi 等［9］提出利用快速傅里叶变换（Fast Fourier Transform, FFT）提取三相电流的谐波谱，通过监控特定倍频成分的幅值变化来识别单桥臂开路故障。针对 FFT 无法提供时间定位信息的缺陷，Khodja 等［10］引入了改进的短时傅里叶变换（Short-Time Fourier Transform, STFT），利用时频窗捕捉非平稳电流信号中的瞬时能量突变。此外，基于克拉克变换（Clark Transformation）的电流轨迹分析法，如 Park’s Vector Approach［11］，通过观察 α - β 坐标系下电流矢量轨迹圆的畸变形状来判定故障类型。尽管这些方法在稳态环境下表现良好，但其本质上仍属于“静态特征匹配”。在变频、变载的动态切换过程中，原始信号的非平稳性显著增强，故障特征往往与工况特征（如电流幅值随负载增加而增大）在频域或时域上高度耦合。由于基于固定基函数或特定频率窗口的提取手段难以自适应地分离出跨域变化的本质特征，导致该类方法在多工况场景下的泛化能力与诊断鲁棒性明显受限［12，13］。

1.3 深度学习的研究现状

随着人工智能技术的飞速发展，以卷积神经网络（Convolutional Neural Network, CNN）、循环神经网络（Recurrent Neural Network, RNN）为代表的深度学习方案已逐渐取代传统的浅层学习模型，成为逆变器故障诊断领域的研究主流［14］。这类方法的核心优势在于能够通过多层非线性映射，直接从原始采样序列中自动挖掘多层次的抽象故障特征，极大地减少了对人工特征选择的盲目性。其研究现状与演进路径主要体现在以下两个方面：

(1)深度学习在特征表征上的突破： 传统诊断依赖人工提取特征，存在较强的盲目性与主观性。在特征自动表征能力的探索上，Zhao 等［15］提

出了一种基于卷积双向长短期记忆网络（Convolutional Bidirectional Long Short-Term Memory, C-BiLSTM）的诊断模型，其核心思想是利用卷积层捕捉三相电流波形的局部空间指纹，并结合双向长短期记忆网络（Bidirectional Long Short-Term Memory, BiLSTM）提取时序演化规律，从而实现了对功率器件早期微弱故障特征的主动挖掘。随后，针对电力电子信号的高频采样特性，Ince 等［5］证明了一维卷积神经网络（One-Dimensional Convolutional Neural Network, 1D-CNN）能够直接处理原始时域信号，显著提升了诊断系统的自动化水平。在国内研究方面，李等［16］提出了基于多尺度卷积神经网络（Multi-Scale Convolutional Neural Network, MSCNN）的方案，核心思想是通过不同尺度的卷积核并行提取信号特征，以增强模型对复杂谐波干扰的识别能力。此外，针对样本稀缺问题，Wang 等［17］利用改进的生成对抗网络（Generative Adversarial Network, GAN）生成故障样本，试图解决工业现场数据分布不均衡带来的模型偏见。

(2)变工况环境下的性能瓶颈： 尽管深度模型在特定实验环境下表现优异，但在实际工程应用中面临严峻挑战。传统的深度学习模型通常遵循“独立同分布（Independent and Identically Distributed, IID）”假设，即要求训练环境（源域）与实际运行环境（目标域）的概率分布保持一致［18, 19］。但在逆变器的实际运行中，负载的剧烈波动、电网电压偏移以及开关频率的调整会导致电流波形的统计特性发生显著偏移（Domain Shift）［20］。Zhang 等［21］的对比实验明确指出，当逆变器从额定工况切换至低载或变频工况时，模型在固定工况下训练得到的判别边界将发生失效，导致分类精度出现“断崖式”下跌。此外，Sun 等［22］研究发现，深度网络往往会过度拟合与工况相关的干扰特征（如随负载波动的电流幅值），而忽略本质的故障判别指纹。这种对工况变化的高度敏感性，导致传统深度学习模型难以在复杂变工况系统中直接部署，从而迫使研究者转向探索具备跨域适应能力的迁移学习方案［23, 24］。

1.4 迁移学习（Transfer Learning）的研究进展

针对深度学习在变工况下的性能瓶颈，研究者们引入了迁移学习（Transfer Learning）中的领域自适应（Domain Adaptation）技术，旨在通过对齐源域（实验室数据）与目标域（实际工况）的特征分布来提升模型的泛化能力［22］。根据对齐策略的不同，目前的研究主要集中在以下三个方向：

(1）基于统计矩对齐的方法

该类方法通过最小化源域与目标域在特征空间中的统计距离实现跨域迁移。其核心思想是寻找一个映射空间，使得两域数据的分布在该空间内

趋于一致。Long 等［25］提出了深度适配网络（Deep Adaptation Network, DAN），利用多核最大均值差异（Multi-Kernel Maximum Mean Discrepancy, MK-MMD）在再生核希尔伯特空间（Reproducing Kernel Hilbert Space, RKHS）中对齐特征的均值嵌入，显著降低了跨工况诊断的误差。此外，Sun 等［26］提出了相关性对齐算法（Deep Correlation Alignment, Deep CORAL），核心思想是通过对齐源域与目标域的二阶统计量（协方差矩阵），在不显著增加计算开销的前提下实现了特征分布的重塑。

这类方法多侧重于全局分布的对齐，往往忽略了逆变器不同故障类别间的细粒度边界。在多故障分类任务中，由于未考虑类别间的条件分布差异，极易导致目标域中相近故障模式的特征在空间中发生混叠，造成误判。

（2）基于对抗特征迁移的方法

受生成对抗网络 GAN 启发，研究者引入博弈论思想来提取工况不变特征。Ganin 等［27］提出的领域对抗神经网络（Domain-Adversarial Neural Network, DANN）是该方向的奠基性工作，其核心思想是引入领域判别器，通过梯度反向传播强制特征提取器生成令判别器无法区分工况来源的特征。随后，Tzeng 等［28］提出了对抗判别自适应（Adversarial Discriminative Domain Adaptation, ADDA）框架，通过非对称映射进一步增强了特征空间的跨域适应性。在电力电子领域，Li 等［29］将此机制应用于逆变器诊断，证明了对抗训练能有效剔除由负载波动产生的干扰信息。

在目标域完全无标签时，此类方法容易出现“负迁移”现象。由于缺乏目标域类标的引导，模型在模糊化工况差异的同时，也可能损害原本具有判别性的故障特征。

（3）基于原型理论与小样本学习的方法

针对实际工业场景中故障样本极难获取的现状，基于原型网络（Prototypical Networks，PN）的研究成为近年来的前沿。Snell 等［30］提出了利用类质心（Prototypes）进行度量学习的框架，核心思想是计算样本与各故障类质心的距离来实现分类。Wang 等［31］进一步结合注意力机制（Attention Mechanism, AM），提出了针对工业时序信号的对齐策略。国内学者如宋等[32]梳理了变工况下基于电机电流信号的深度迁移与元学习研究进展。

虽然质心对齐为变工况提供了新路径，但如何在动态切换的工况下实现质心的实时更新，以及如何应对故障特征与工况干扰高度耦合的难题，仍是当前研究的薄弱环节［4］。

1.5　发展态势与趋势

随着工业 4.0 与能源互联网概念的深度融合，逆变系统的故障诊断技术的核心发展趋势可概括为以下四个维度：

（1）高度自动化的端到端诊断逻辑：

传统方法高度依赖于时频域变换（如小波包分解等）的繁琐预处理，这不仅增加了算法延迟，也限制了诊断的泛化性。未来趋势是直接利用端到端（End-to-End）的神经网络结构，如一维卷积神经网络（1D-CNN）或时间卷积网络（Temporal Convolutional Network, TCN），实现从原始电信号到故障类别的直接映射，最大程度保留原始信号中的相位与幅值关联，提升诊断系统的自动化水平 [33]。

（2）极小样本及非平衡工况下的算法稳健性：

实际工程中，功率器件的真实故障样本属于“稀有事件”，而正常运行数据海量存在，导致严重的样本不均衡问题。结合生成对抗网络（GAN）的过采样技术以及基于元学习（Meta-Learning）的小样本学习策略，使模型在仅有少量故障记录的条件下仍能保持高精度检测，是目前工业界迫切需要突破的技术瓶颈 [34]。

（3）跨域融合的多源信息诊断体系：

单纯依赖三相电流信号难以实现对功率器件复杂劣化过程（如键合线脱落、电热老化）的全面捕捉。未来的研究态势是将电信号（电流、电压）与物理域信号（结温监控、高频振动、声发射信号）进行多源信息融合 [35]。通过跨域特征耦合分析，可以从更深维度揭示故障演化机理。

（4）针对嵌入式平台的模型轻量化与实时化：

逆变器故障封锁通常要求在微秒级别完成，以避免二次过流损坏。目前的深度学习模型普遍庞大，难以直接部署于主控 DSP 或 FPGA 中。因此，研究网络剪枝（Pruning）、知识蒸馏（Knowledge Distillation）以及如 ECA 这种极低参数量的轻量化注意力模块，以实现复杂迁移算法在嵌入式边缘端的实时推理，是当前学术界与工业界共同关注的技术热点 [36][37]。

参考文献

[1] Blaabjerg F, Ionel D M. Renewable energy devices and systems – state-of-the-art technology, research and development, challenges and future trends[J]. Electric Power Components and Systems, 2015, 43(12): 1319-1328.

[2] Yang S, Xiang D, Bryant A, et al. Condition monitoring for device reliability in power electronic converters: A review[J]. IEEE transactions on power

electronics, 2010, 25(11): 2734-2752.
[3] Dang H L, Kim J, Kwak S, et al. Series DC arc fault detection using machine learning algorithms[J]. IEEE Access, 2021, 9: 133346-133364
[4] 宋向金, 赵文祥. “交流电机信号特征分析的滚动轴承故障诊断方法综述” [J]. 中国电机工程学报, 2022, 42(4): 1582-1595.Ince T, Kiranyaz S, Eren L, et al. Real-time motor fault detection by 1-D convolutional neural networks[J]. IEEE Transactions on Industrial Electronics, 2016, 63(11): 7067-7075.
[5] Gao Z, Cecati C, Ding S X. A survey of fault diagnosis and fault-tolerant techniques — Part I: Fault diagnosis with model-based and signal-based approaches[J]. IEEE transactions on industrial electronics, 2015, 62(6): 3757-3767.
[6] Zhang Y, Wang Z, Jiao J, et al. Grid-voltage sensorless model predictive control of three-phase PWM rectifier under unbalanced and distorted grid voltages[J]. IEEE Transactions on Power Electronics, 2019, 35(8): 8663-8672.
[7] Ding S X. Data-driven design of fault diagnosis and fault-tolerant control systems[M]. London: Springer London, 2014.
[8] Xia Y, Gou B, Xu Y. A new ensemble-based classifier for IGBT open-circuit fault diagnosis in three-phase PWM converter[J]. Protection and Control of Modern Power Systems, 2018, 3(1): 33.
[9] Khodja M E A, Aimer A F, Boudinar A H, et al. Bearing fault diagnosis of a PWM inverter fed-induction motor using an improved short time Fourier transform[J]. Journal of Electrical Engineering & Technology, 2019, 14(3): 1201-1210.
[10] Cardoso A J M, Mendes A M S, Cruz S M A. The Park’s vector approach: New developments in on-line fault diagnosis of electrical machines, power electronics and adjustable speed drives[C]//Proc. IEEE Int. Symp. Diagnostics for Electrical Machines, Power Electronics and Drives. 1999: 1-3.
[11] 魏慕恒, 等. 基于信号处理的电力电子变换器故障诊断研究综述 [J]. 电机与控制学报, 2022.
[12] Xiao Q, Jin Y, Jia H, et al. Review of fault diagnosis and fault-tolerant control methods of the modular multilevel converter under submodule failure[J]. IEEE Transactions on Power Electronics, 2023, 38(10): 12059-12077.
[13] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. nature, 2015, 521(7553): 436-444.
[14] Zhao R, Yan R, Wang J, et al. Learning to monitor machine health with

convolutional bi-directional LSTM networks[J]. Sensors, 2017, 17(2): 273.
[15]李等. 基于多尺度卷积神经网络的逆变器开关管故障诊断 [J]. 中国电机工程学报, 2021.
[16]Zhang W, Li X, Jia X D, et al. Machinery fault diagnosis with imbalanced data using deep generative adversarial networks[J]. Measurement, 2020, 152: 107377.
[17]Goodfellow I, Bengio Y, Courville A, et al. Deep learning[M]. Cambridge: MIT press, 2016.
[18]Zhao R, Yan R, Chen Z, et al. Deep learning and its applications to machine health monitoring[J]. Mechanical Systems and Signal Processing, 2019, 115: 213-237.
[19]Pan S J, Yang Q. A survey on transfer learning[J]. IEEE Transactions on knowledge and data engineering, 2009, 22(10): 1345-1359.
[20]Zhang W, Peng G, Li C, et al. A new deep learning model for fault diagnosis with good anti-noise and domain adaptation ability on raw vibration signals[J]. Sensors, 2017, 17(2): 425.
[21]Li T, Zhao Z, Sun C, et al. Multireceptive field graph convolutional networks for machine fault diagnosis[J]. IEEE Transactions on Industrial Electronics, 2020, 68(12): 12739-12749.
[22]Shao H, Xia M, Han G, et al. Intelligent fault diagnosis of rotor-bearing system under varying working conditions with modified transfer convolutional neural network and thermal images[J]. IEEE Transactions on Industrial Informatics, 2020, 17(5): 3488-3496.
[23]魏慕恒, 等. 基于深度学习的电力电子变换器故障诊断研究综述 [J]. 电机与控制学报, 2022.
[24]Long M, Cao Y, Wang J, et al. Learning transferable features with deep adaptation networks[C]//International conference on machine learning. PMLR, 2015: 97-105.
[25]Sun B, Saenko K. Deep coral: Correlation alignment for deep domain adaptation[C]//European conference on computer vision. Cham: Springer International Publishing, 2016: 443-450.
[26]Ganin Y, Lempitsky V. Unsupervised domain adaptation by backpropagation[C]//International conference on machine learning. PMLR, 2015: 1180-1189.
[27]Tzeng E, Hoffman J, Saenko K, et al. Adversarial discriminative domain adaptation[C]//Proceedings of the IEEE conference on computer vision and

pattern recognition. 2017: 7167-7176.
[28]Li Y, Song Y, Jia L, et al. Intelligent fault diagnosis by fusing domain adversarial training and maximum mean discrepancy via ensemble learning[J]. IEEE Transactions on Industrial Informatics, 2020, 17(4): 2833-2841.
[29]Snell J, Swersky K, Zemel R. Prototypical networks for few-shot learning[J]. Advances in neural information processing systems, 2017, 30.
[30]Jiang C, Chen H, Xu Q, et al. Few-shot fault diagnosis of rotating machinery with two-branch prototypical networks[J]. Journal of Intelligent Manufacturing, 2023, 34(4): 1667-1681.
[31]宋向金, 赵文祥. “交流电机信号特征分析的滚动轴承故障诊断方法综述” [J]. 中国电机工程学报, 2022, 42(4): 1582-1595.
[32]Ince T, Kiranyaz S, Eren L, et al. Real-time motor fault detection by 1-D convolutional neural networks[J]. IEEE Transactions on Industrial Electronics, 2016, 63(11): 7067-7075.
[33]Wang J, Ma Y, Zhang L, et al. Deep learning for smart manufacturing: Methods and applications[J]. Journal of manufacturing systems, 2018, 48: 144-156.
[34]Alcaide A M, Buticchi G, Chub A, et al. Design and control for high-reliability power electronics: State-of-the-art and future trends[J]. IEEE Journal of Emerging and Selected Topics in Industrial Electronics, 2023, 5(1): 50-61.
[35]Zhang X, Zhou X, Lin M, et al. Shufflenet: An extremely efficient convolutional neural network for mobile devices[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6848-6856.
[36]高宏伟, 等. 面向嵌入式应用的电力电子变换器深度学习诊断模型压缩技术 [J]. 电工技术学报, 2024.

2. 选题意义

（1）学术意义：探索非平稳信号下的知识迁移机制

本研究通过引入迁移学习策略，探索逆变系统在多工况下故障特征的演变规律。研究如何利用深度网络提取具有“工况不变性”的鲁棒特征，不仅丰富了电力电子故障诊断的理论体系，也为非平稳时间序列信号的跨域处理提供了新的思路和方法。

（2）实践意义：降低故障诊断系统的维护成本

解决小样本问题：在实际工业现场，获取特定工况下的故障样本（尤

其是破坏性实验数据）成本极高且危险。本课题通过迁移学习，可以利用容易获取的仿真数据或历史工况数据来辅助诊断，极大降低了对实地故障数据的依赖。

提升诊断系统的鲁棒性：研发的故障检测模型能够自动适应负载波动和环境变化，减少误报和漏报。

支撑智能化运维：该方法为逆变系统的状态监测（Condition Monitoring）提供了核心算法支持，有助于实现从“事后维修”到“预测性维护”的转变，具有显著的经济价值。

3．课题研究内容

本课题以多工况下的逆变系统为研究对象，采用基于迁移学习的 信息分离全局焦点对抗网络（Information separation global-focal adversarial network，ISGFAN）深度神经网络架构，利用逆变器运行产生的电流、电压时序数据进行故障检测，主要包括以下四方面内容：

(1) 实验平台搭建与实际运行数据的采集，分析逆变器在不同工况下的特征演变与信号预处理：

搭建实验平台，实现对 IGBT 运行过程中运行相关数据的连续采集；基于现实中 IGBT 常见故障机理，结合平台实际，设计合适的故障方式并植入，实现对 IGBT 故障数据的采集。深入分析逆变器在不同负载率与输出频率下，电流/电压信号统计特性的变化规律，探究工况波动导致信号分布偏移（Domain Shift）的内在机理；

(2) 构建基于注意力机制的信息分离网络,实现特征精准解耦：

在原 ISGFAN 信息分离架构的基础上进行改进，引入轻量化注意力机制（Attention Mechanism），通过学习权重系数自动识别并增强故障判别核心特征，同时抑制随工况波动的干扰特征；

引入正交约束项确保故障特征空间与工况私有空间完全解耦，从根本上提取具有“工况不变性”的纯净故障特征。

(3) 针对目标域无标签场景设计动态类中心同步策略：

针对目标域工况多样且完全无标签的难题，对 ISGFAN 框架中的局部对齐策略进行优化，设计一种动态更新的类中心（Dynamic Centroids）同步机制；

在训练过程中根据预测置信度实时估计目标域各故障类的“虚拟中心”，并强制其向源域标准中心靠拢，解决多工况下局部特征分布错位问题。

(4) 模型轻量化改进与多工况泛化性能评估：

针对逆变系统实时监测需求，通过冗余架构剪枝实现模型轻量化，降低计算复杂度；

在单一源域训练的基础上，验证模型对多个未知目标工况的检测精度；利用 t-分布随机邻域嵌入（t-Distributed Stochastic Neighbor Embedding, t-SNE）等算法对提取的特征进行可视化分析，验证模型在复杂变工况场景下的泛化边界与实时响应性能。

4. 拟解决的关键问题和最终目标，以及拟采取的主要理论、技术路线和实施方案等

4.1 拟解决的关键问题

（1）故障特征与运行工况的深度解耦：

针对逆变器电流信号中故障信息与工况干扰高度耦合的难题，研究如何利用注意力机制与信息分离架构，在单源域约束下有效抑制负载及频率波动的干扰，精准提取具有工况不变性的故障核心特征。

（2）目标域无标签情况下的跨域类别对齐：

针对实际应用中目标工况种类繁多且缺乏标注信息的问题，研究如何通过动态类中心同步算法，在无监督条件下实现源域与目标域特征的精确映射，解决因工况差异导致的类别偏移与诊断误判。

（3）诊断精度与实时响应性能的协同优化：

针对深度迁移模型计算开销大与逆变器故障保护实时性要求高之间的矛盾，研究如何通过架构裁剪与轻量化设计，在保持模型多工况泛化能力的同时降低推理延迟，提升算法在嵌入式端落地的可行性。

4.2 最终目标

构建一个基于改进 ISGFAN 框架的多工况逆变器故障检测系统。实现仅利用额定工况数据完成训练，即可对多种未知变工况场景（不同负载、频率组合）进行高精度识别。最终模型应具备较强的普适性，在保证检测准确率的同时，具备较低的计算延迟，满足工业现场的实时监控需求。

4.3 拟采取的主要理论

（1）迁移学习（Transfer Learning）理论

迁移学习是机器学习领域的一个重要分支，其核心目标是利用源域（Source Domain）中学习到的知识，通过特征映射与知识迁移，辅助目标

域（Target Domain）任务的学习与优化。在逆变器故障诊断的实际工程场景中，设备往往面临负载剧烈波动、电网频率切换等复杂多变的运行工况。根据统计学习理论，这种工况的改变会导致传感器采集的电流、电压等原始信号在时域分布与频域特性上产生显著的“领域偏移”（Domain Shift）。若直接采用传统监督学习模型，由于源域（实验室额定工况）与目标域（现场变工况）的概率分布不一致，模型往往会出现严重的过拟合及泛化性能跌落现象。

本课题拟深入研究迁移学习中的领域自适应（Domain Adaptation）理论。该理论假设源域与目标域虽然边缘分布不同，但存在共同的特征表示空间。本研究拟构建深层神经网络作为特征映射函数，将原始多工况信号投影至高维潜在特征空间。在该空间内，通过引入最大均值差异（MMD）度量准则或采用对抗判别机制，计算并最小化源域与目标域特征分布之间的散度距离。

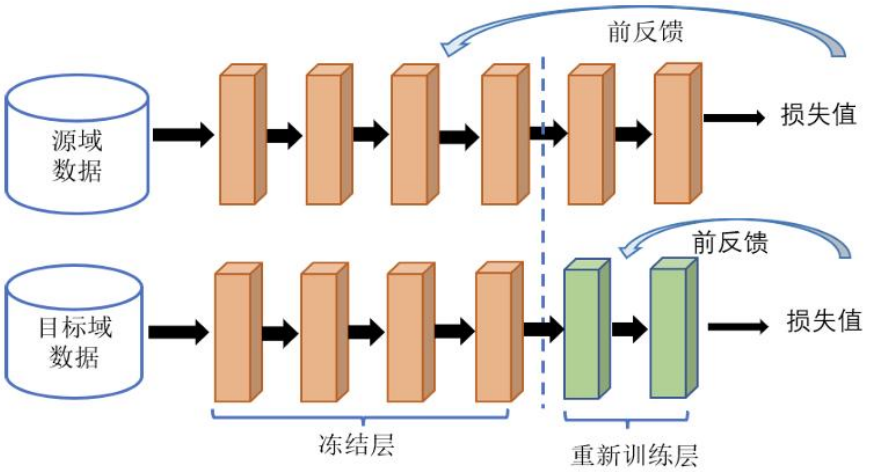

图 1 迁移学习原理

（2）信息分离（Information Separation, IS）理论

信息分离理论是解耦表示学习（Disentangled Representation Learning）在故障诊断领域的重要应用，其核心目标是将观测信号中交织的多维特征按照物理属性或语义信息进行独立表征。在逆变器多工况故障检测任务中，原始信号由故障判别信息与运行工况干扰高度耦合而成。传统方法往往将二者视作整体处理，导致模型在面对负载或频率剧烈切换时，难以从波动的特征中精准捕捉微弱的故障指纹。

本课题拟采用基于双流编码器架构的信息分离理论。该理论将特征空间划分为故障特征空间（Sharing Feature Space）与工况私有空间（Private Feature Space）：

故障特征提取：通过共享编码器捕获源域与目标域中具有“工况不变性”的核心特征。这一部分特征仅反映逆变器内部开关器件的状态（如开

路、短路等），而不随外部负载的大小或频率的波动而偏移。

私有信息剔除：利用私有编码器专门捕获工况相关的偏移量（Domain-specific features）。通过这种显式的分离，模型可以有效地将复杂的工况波动限制在私有空间内，避免其对故障判别逻辑产生干扰。

为了保证分离的彻底性，本研究拟引入正交约束损失函数（Orthogonality Constraint）。该损失函数通过计算共享空间与私有空间向量的内积，强制要求两类特征向量在空间分布上保持正交。这种约束机制能够确保故障特征与工况特征之间不存在信息冗余与相互渗透，从而提升特征表达的纯净度。

（3）注意力机制（Attention Mechanism）理论

注意力机制是模拟人类视觉系统对关键信息进行聚焦的深度学习理论，其核心思想是在处理海量信息时，通过自适应分配权重，将计算资源集中于高贡献度的特征片段，而忽略冗余或干扰项。在逆变器多工况故障检测中，电力电子信号往往伴随着复杂的谐波干扰与随机噪声，且故障特征在时域或频域上的分布具有非均匀性。

本课题拟引入通道注意力（Channel Attention）与空间注意力（Spatial Attention 协同机制（Convolutional Block Attention Module, CBAM）。由于逆变器输出的电流、电压信号在经过二维图像化转换后，不同通道（如格拉姆角场的分量）代表了信号的不同物理维度，而图像的不同区域则对应不同的时间点或频率成分。通过注意力机制，模型可以实现对关键特征的主动聚焦，自动识别出对故障类别最具判别性的频率段或相位点，赋予其较高的增益；同时削弱对工况无关信息的响应，起到物理含义上的“特征滤波器”作用。这为后续的“信息分离”提供了高纯度的输入特征，缓解模型在单源域训练时因工况噪声过强而导致的特征混淆问题。

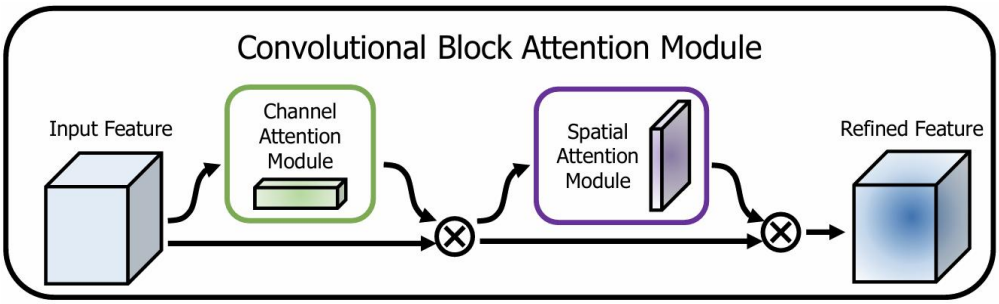

图 2 CBAM 示意图

4.4 拟采取的技术路线

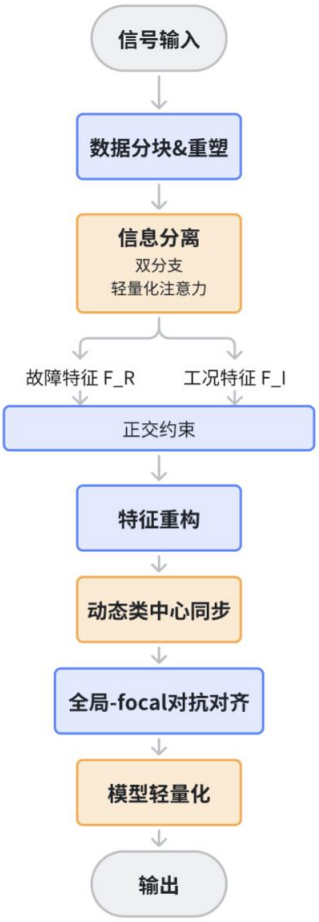

图 3 本课题拟采用路线图技术

本课题拟采用的的主要技术路线如上图所示。

5. 论文特色或创新点

1. 在 ISGFAN 的信息分离双分支中引入轻量化 CBAM 注意力，可学习通道-空间权重，精准抑制工况噪声干扰，实现故障特征与工况特征的高纯度解耦。

2. 提出“动态类中心同步”机制：仅用高置信伪标签在线更新源/目标域中心向量，并增加中心距离损失，显式拉近两域同类样本，解决无标签场景下局部分布错位难题。

3. 通过架构裁剪与轻量化设计压缩模型参数，并完成多工况逆变系统故障迁移测试，兼顾实时性与多工况泛化能力。

导师审查意见	**签名：** **日期：　　年　　月　　日**